

**TalentMap AI - Aplicación Ética y Técnica de IA en el Emparejamiento de Candidatos y  
Ofertas Laborales**

**Autores:**

Santiago Botero García

Andrés Felipe Calderón Ramírez

**Curso:** PTIA-2 - *Principios y Tecnologías de Inteligencia Artificial*

**Profesor:** Juan Sebastián Martínez Serna

**Fecha:** Diciembre 9, 2025

## **Resumen**

Este proyecto propone una solución basada en inteligencia artificial (IA) para mejorar la eficiencia en la vinculación de candidatos con las vacantes disponibles en las empresas. El proyecto propone el desarrollo de un modelo de IA, denominado TalentMap AI, diseñado para evaluar la correspondencia entre currículums y descripciones de puestos mediante análisis semántico.

El objetivo es optimizar la relación entre las habilidades y características de un candidato y los requisitos técnicos y culturales de la empresa, mejorando así la calidad de las recomendaciones en comparación con los sistemas tradicionales basados únicamente en palabras clave.

El proyecto combina la tecnología de procesamiento del lenguaje natural (PLN) con un modelo semántico, considerando también consideraciones éticas, transparencia y sesgo algorítmico en el proceso de recomendación.

*Palabras clave.* inteligencia artificial, empleabilidad, procesamiento del lenguaje natural, sistemas de recomendación, ética de la IA, Transformer, modelo semántico, sesgo algorítmico.

## Contenido

Resumen.....	2
1. Introducción .....	4
2. Exploración del problema .....	4
3. Estado del arte.....	5
3.1. Aprendizaje automático y predicción del comportamiento .....	5
3.2. Recomendaciones laborales y correspondencia semántica.....	6
4. Definición del problema .....	7
6. Solución propuesta.....	11
6.1. Enfoque general .....	11
6.2. Técnicas y herramientas.....	11
6.3. Prototipo y despliegue.....	11
7. Aspectos éticos y reflexivos.....	12
8. Diseño de la arquitectura .....	12
9. Casos de prueba exitosos .....	16
10. Casos de prueba en falla .....	18
11. Conclusiones .....	19
Bibliografía .....	20

## **1. Introducción**

Hoy en día, la inteligencia artificial (IA) se define como la disciplina que busca desarrollar sistemas capaces de realizar tareas que normalmente requieren inteligencia humana, como el razonamiento, el aprendizaje o la comprensión del lenguaje (Russell & Norvig, 2021). Estas tecnologías permiten procesar grandes volúmenes de información para tomar decisiones o realizar predicciones de manera autónoma. Este campo abarca diversas ramas, como el aprendizaje automático y el procesamiento del lenguaje natural (PLN), que permiten a las máquinas comprender y analizar texto, imágenes o datos de comportamiento.

El curso PTIA (Principios y Técnicas de la Inteligencia Artificial) tiene como objetivo aplicar estos fundamentos técnicos y éticos al diseño de soluciones funcionales, priorizando los modelos de IA como productos mínimos viables (MVP).

En este contexto, proponemos el modelo de IA TalentMap, que busca reducir la fricción en el proceso de empleo mediante la vinculación inteligente de candidatos con las oportunidades laborales e integra elementos técnicos y éticos de la IA.

## **2. Exploración del problema**

Según el Foro Económico Mundial (2024), más del 44% de las habilidades laborales actuales serán alteradas por la automatización y los avances tecnológicos, generando una brecha creciente entre las competencias de los trabajadores y las demandas empresariales. Este desajuste afecta especialmente a los jóvenes profesionales en búsqueda de su primer empleo. Las plataformas de reclutamiento tradicionales emparejan a los candidatos basándose en palabras clave, ignorando matices semánticos como las habilidades interpersonales, la compatibilidad cultural o el potencial de desarrollo.

Esto genera emparejamientos imprecisos, insatisfacción de los usuarios y pérdida de tiempo y recursos de la empresa. Según el estudio de CareerBERT, "Matching Resumes to ESCO Jobs in a Shared Embedding Space for Universal Job Recommendations", más del 70% de los procesos de contratación son inefficientes debido a la sobrecarga de información y a la falta de herramientas inteligentes para filtrar perfiles contextualmente.

Esto presenta un desafío no solo técnico, sino también ético. Los sistemas automatizados pueden amplificar sesgos o excluir grupos sociales si no se diseñan cuidadosamente. Por lo tanto, TalentMap AI se esfuerza por equilibrar la capacidad predictiva de sus modelos con la imparcialidad e interpretabilidad de sus resultados.

### **3. Estado del arte**

Investigaciones recientes analizan investigaciones y desarrollos previos sobre el uso de la inteligencia artificial para mejorar la empleabilidad y la toma de decisiones humanas.

#### **3.1. Aprendizaje automático y predicción del comportamiento**

- Facebook language predicts depression in medical records
- Eichstaedt et al. (2018) desarrollaron un modelo predictivo que detecta síntomas depresivos con más del 70% de precisión mediante el análisis de publicaciones en redes sociales.
  - **¿Qué?** Un modelo de detección de sentimientos basado en texto.
  - **¿Como?** Utilizando aprendizaje automático y análisis del lenguaje.
  - **¿Para Qué?** Predecir el diagnóstico y promoviendo la intervención temprana.
- **Early Dropout Prediction in Online Learning of University using Machine Learning**

- Park y Yoo (2021) utilizaron clasificadores como bosques aleatorios y redes neuronales para predecir las tasas de abandono universitario utilizando datos de una plataforma LMS.
  - **¿Qué es?** Un modelo de predicción académica.
  - **¿Cómo?** Extracción de variables de comportamiento estudiantil.
  - **¿Para Qué?** Prevenir el abandono escolar y optimizando las estrategias institucionales.

### **3.2. Recomendaciones laborales y correspondencia semántica**

- CareerBERT: Matching Resumes to ESCO Jobs in a Shared Embedding Space for Generic Job Recommendations
- Rosenberger et al. (2025) propusieron CareerBERT, un sistema de recomendación de empleo que utiliza un modelo Transformer para representar perfiles y empleos en el mismo espacio semántico.
  - **¿Qué es?** Un modelo basado en incrustaciones semánticas.
  - **¿Cómo funciona?** Utiliza representaciones vectoriales de currículums y ofertas de empleo.
  - **¿Por qué?** Para mejorar la precisión de la correspondencia entre candidatos y ofertas de empleo.
- Embedding in Recommender Systems: A Survey
- Zhao et al. (2023) realizaron un análisis exhaustivo de los sistemas de recomendación basados en incrustaciones, destacando que técnicas como las redes neuronales, el aprendizaje autónomo y los modelos de representación semántica superan

significativamente los métodos tradicionales de coincidencia de palabras clave al capturar las complejas relaciones entre usuarios y empleos.

- **¿Qué es?** Un sistema de recomendación basado en incrustaciones.
- **¿Cómo funciona?** Utiliza redes neuronales y aprendizaje autosupervisado para representar semánticamente a usuarios y ofertas de empleo.
- **¿Por qué?** Mejorar la precisión y relevancia de las recomendaciones capturando relaciones más profundas y complejas entre los perfiles de usuario y las ofertas de empleo.

En conjunto, estos estudios demuestran que el uso de redes neuronales semánticas y modelos Transformer como BERT representa un avance significativo en las tareas de correspondencia del contexto de texto, lo que constituye la base teórica de TalentMap AI.

#### **4. Definición del problema**

El problema principal es la ineficiencia en los procesos de selección de personal. Los sistemas y portales actuales no captan adecuadamente la correspondencia entre los perfiles de los candidatos y los requisitos específicos de las vacantes, lo que puede generar desajustes en la contratación, mayor rotación y pérdida de talento.

El impacto de esta brecha y sus indicadores clave de desempeño (KPI) son los siguientes:

- **Organacional:** Una selección inadecuada de personal puede tener consecuencias serias para la organización desde pérdida de productividad y recursos hasta aumento de costos operativos. Estudios sobre el costo de malas contrataciones muestran que dichas decisiones equivocadas pueden representar entre 1.5 a 2 veces el salario anual del empleado en costos totales por reemplazo, entrenamiento y bajo desempeño (Sáenz &

Sáenz, 2012). Además, las empresas reportan que una mala contratación ralentiza flujos de trabajo y debilita la eficiencia operativa (*The True Cost Of Bad Hire | Collavion*, s. f.).

- **Económico:** Los procesos de contratación ineficientes aumentan los costos empresariales y reducen la retención del talento. Según MGR WORKFORCE (*Employee Retention: What Employee Turnover Really Costs Your Company*, 2023) estima que reemplazar a un empleado cuesta entre 6 y 9 meses de su salario anual, considerando reclutamiento, entrevistas y entrenamiento. KPIs económicos seleccionados:
  - Costo promedio de contratación (en COP).
  - Tasa de rotación de empleados en los primeros 12 meses.
  - Tiempo promedio de incorporación productiva (meses).
  - Porcentaje de ahorro estimado tras implementar un modelo de IA en reclutamiento.
- **Ético:** El uso de algoritmos en selección puede amplificar sesgos por género, edad o etnia si los datos no se tratan adecuadamente. Estudios recientes advierten que los sistemas de recomendación laboral tienden a priorizar perfiles dominantes, perpetuando desigualdades ((Raghavan et al., 2020; *Help Wanted*, n.d.). KPIs éticos seleccionados:
  - Porcentaje de diversidad en las recomendaciones (género, etnia).
  - Número de auditorías de sesgo realizadas por año.
  - Tasa de reclamos o apelaciones por sesgo algorítmico.

Por lo tanto, este proyecto busca mejorar la precisión y equidad del emparejamiento laboral mediante modelos de inteligencia artificial aplicables, justos y auditables, reduciendo tanto la fricción en los procesos de selección como el impacto de sesgos en las decisiones automatizadas.

De acuerdo con el modelo P.E.A.S., el sistema propuesto se define de la siguiente manera:

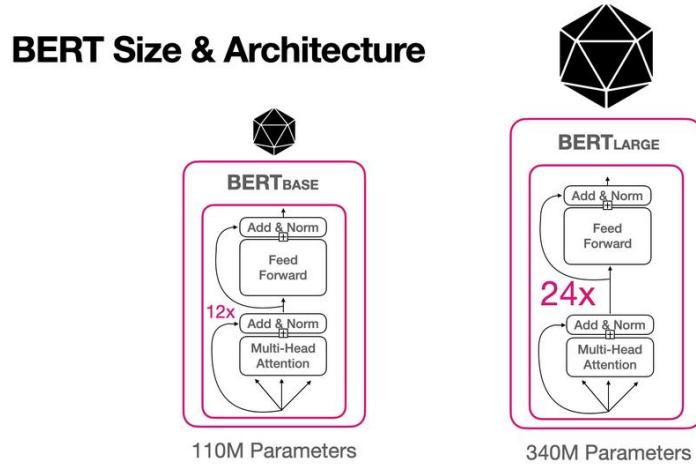
- **Performance (Desempeño):** Nivel de precisión del emparejamiento candidato–vacante.
- **Environment (Entorno):** Datos de currículos y descripciones laborales.
- **Actuators (Actuadores):** Recomendaciones generadas y métricas de compatibilidad.
- **Sensors (Sensores):** Entradas textuales procesadas por el modelo PLN.

## 5. Objetivos del proyecto

- **Objetivo general:** Desarrollar un modelo de IA que utilice incrustaciones semánticas para analizar la compatibilidad entre descripciones de puestos y currículums, logrando una precisión superior al 90% en la predicción de coincidencias. Estudios como de CareerBERT, "Matching Resumes to ESCO Jobs in a Shared Embedding Space for Universal Job Recommendations", alcanzan niveles de precisión del 88% en emparejamiento semántico laboral, por lo que establecer un objetivo superior al 90% constituye una meta desafiante pero viable para el MVP.
- **Objetivos específicos:**
  1. Implementar un prototipo funcional del modelo mediante técnicas de procesamiento del lenguaje natural (PLN) e incrustaciones (DistilBERT).

**Figura 1**

*Arquitectura del modelo BERT*



*Nota.* Se presentan dos configuraciones de BERT: una con 12 capas y 110 millones de parámetros, y otra con 24 capas y 340 millones. Ambas incluyen los módulos principales de su arquitectura.

*Fuente.* <https://quantpedia.com/app/uploads/2023/07/Picture-301-BERT-architecture.png>

2. Entrenar y evaluar el modelo con datasets laborales, midiendo su rendimiento mediante métricas de precisión, recall y F1-score.
3. Diseñar mecanismos de explicabilidad y auditoría para detectar y mitigar sesgos algorítmicos.
4. Validar el prototipo como producto mínimo viable (MVP) aplicable a procesos de selección de personal en empresas.

## 6. Solución propuesta

### 6.1. Enfoque general

La solución se centra en el motor de emparejamiento, el núcleo inteligente del sistema, que concentra el conocimiento y el razonamiento. Este motor puede interpretar el lenguaje natural de los currículums y las ofertas de empleo y generar una representación numérica que permite medir el grado de coincidencia.

### 6.2. Técnicas y herramientas

- **Lenguaje y framework:** Python, con Django como backend.
- **Modelos preentrenados:** DistilBERT (para incrustaciones semánticas).
- **Dataset:** No se encontraron conjuntos de datos de entrenamiento que se ajustaran a nuestras necesidades específicas. Por lo tanto, se creó un conjunto de datos propio basado en currículums, complementando, cuando fue posible, el Resumes Dataset proporcionado por Hugging Face, que contiene currículums en inglés en formato JSON. Este recurso se utilizará para entrenar y validar el modelo de análisis de perfiles laborales.

### 6.3. Prototipo y despliegue

Este MVP está diseñado para demostrar el funcionamiento de un modelo de IA en tiempo real. En lugar de entrenar el modelo durante la ejecución, la aplicación utiliza el conjunto de datos definido en el paso anterior. Al usar la aplicación, los usuarios pueden subir un currículum vitae (CV) a través de la interfaz web. El sistema realizará la tarea de clasificación directamente desde el front-end y pasará los datos a un servicio REST que ejecuta el modelo.

La capa web será una SPA (aplicación de página única) básica, diseñada específicamente para visualizar los resultados del MVP y facilitar la comprensión del flujo de trabajo del modelo. Para simplificar el desarrollo y centrarnos en el modelo de IA.

## 7. Aspectos éticos y reflexivos

TalentMap AI aborda la inteligencia artificial desde una perspectiva ética y responsable. Según la UNESCO (2021), un desarrollo ético de la IA requiere equidad, transparencia y responsabilidad en los sistemas automatizados, principios aplicables directamente a TalentMap AI. Las consideraciones incluyen:

- **Sesgo algorítmico:** Garantizar que los datos de entrenamiento no discriminan por género, edad o ubicación.
- **Privacidad:** Anonimizar currículums y descripciones.
- **Transparencia:** Explicar el funcionamiento del modelo y sus limitaciones.

El objetivo no es solo construir un modelo viable, sino también comprender su impacto social.

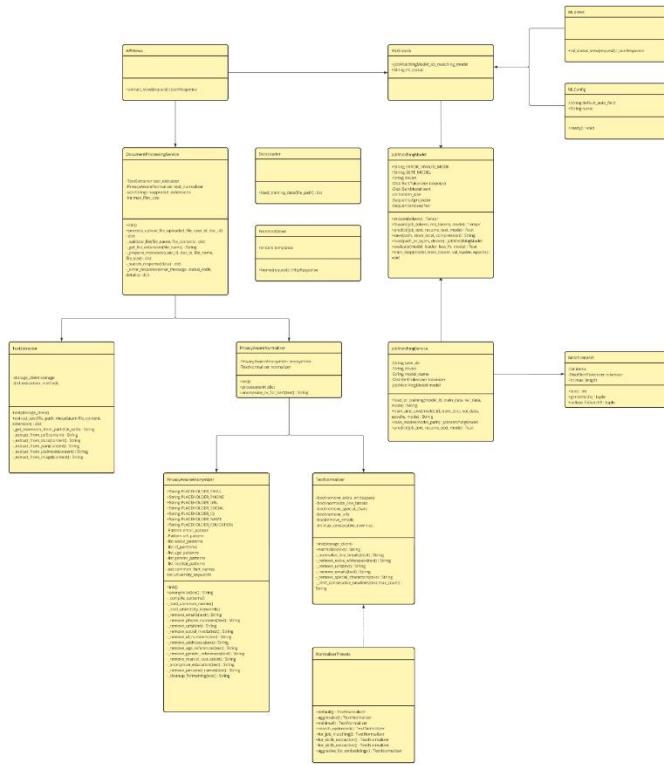
## 8. Diseño de la arquitectura

El sistema utiliza un conjunto de clases orientadas al procesamiento y anonimización del texto, comenzando con TextExtractor, que obtiene el contenido de archivos; seguido por TextTransformer y PreprocessorNormalizer, que limpian, estandarizan y transforman la información para eliminar datos sensibles. La clase PreprocessorClassifier identifica patrones

como nombres, correos o direcciones, permitiendo reemplazarlos por versiones anónimas definidas en NormalizerPresets. Una vez que el texto está anonimizado y normalizado, entra en la parte de emparejamiento laboral, donde JobMatchingService coordina el uso de JobMatchingModel, un modelo de machine learning encargado de generar representaciones del texto y comparar perfiles con ofertas. Finalmente, MatchResult encapsula el puntaje de compatibilidad y las coincidencias relevantes, cerrando el flujo desde la anonimización hasta el cálculo de la mejor oferta de empleo para un perfil.

**Figura 2**

*Diagrama de clases del Sistema y Proceso de Emparejamiento de Currículums*



*Nota.* Diagrama de clases del sistema propuesto para TalentMap AI. El flujo comienza con la extracción, anonimización y normalización del texto de los currículums, seguido por el proceso

de emparejamiento utilizando el modelo de machine learning. El sistema evalúa la compatibilidad entre el perfil del usuario y las ofertas de empleo, presentando finalmente los resultados de la coincidencia.

El modelo fue entrenado utilizando una configuración basada en el método de cosine similarity para la medición de similitud entre los currículums y las ofertas laborales. El proceso de entrenamiento consistió en 15 épocas de ajuste de los parámetros del modelo, con un tamaño de lote (batch size) de 32. Se utilizó una tasa de aprendizaje (learning rate) de 3e-05 para controlar la velocidad de ajuste de los pesos del modelo durante el proceso de optimización.

Se optó por no congelar la capa de BERT, permitiendo que todas las capas del modelo se ajustaran durante el entrenamiento para aprovechar al máximo la capacidad de representación de DistilBERT en el contexto del análisis de currículums. El dataset de entrenamiento utilizado consistió en 2048 entradas, mientras que el conjunto de validación estuvo compuesto por 700 muestras, lo que permitió evaluar el desempeño del modelo en datos no vistos durante el entrenamiento. Esta configuración fue elegida para asegurar un balance adecuado entre el ajuste del modelo y la capacidad de generalización a nuevos datos.

La siguiente tabla presenta los valores de pérdida (loss) tanto para el conjunto de entrenamiento como para el de evaluación a lo largo de las 15 épocas de entrenamiento. Se incluyen dos columnas para cada conjunto: la pérdida de entrenamiento y la pérdida de evaluación. Estos datos permiten observar la evolución del modelo en ambas fases, proporcionando una visión clara de su capacidad para ajustarse a los datos de entrenamiento y su rendimiento en datos no vistos.

<b>Época</b>	<b>Perdida de entrenamiento</b>	<b>Perdida de evaluación</b>
1	0.1998	0.1821
2	0.1029	0.1493
3	0.0664	0.1390
4	0.0494	0.1391
5	0.0368	0.1378
6	0.0300	0.1432
7	0.0248	0.1310
8	0.0217	0.1314
9	0.0173	0.1311
10	0.0141	0.1285
11	0.0125	0.1296
12	0.0113	0.1302
13	0.0098	0.1280
14	0.0087	0.1285
15	0.096	0.1312

A lo largo del entrenamiento, se observó una disminución significativa en la pérdida de entrenamiento, lo que indica que el modelo logró ajustarse muy bien a los datos de entrenamiento. Sin embargo, la pérdida de evaluación mostró una tendencia más estable, sin una mejora considerable después de las primeras épocas, lo que sugiere que el modelo comenzó a sobreajustarse (overfitting) a los datos de entrenamiento. Este comportamiento es especialmente

evidente en las últimas épocas, donde la pérdida de entrenamiento sigue descendiendo, pero la pérdida de evaluación se mantiene relativamente constante.

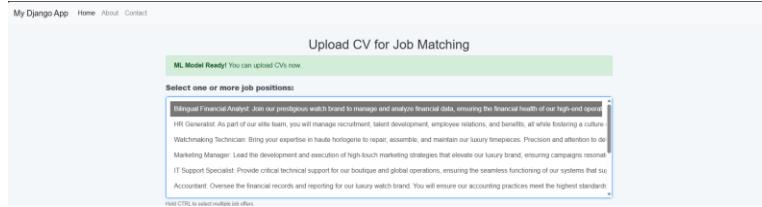
A pesar de realizar múltiples intentos de ajuste, no se logró reducir el overfitting de manera significativa. La razón de esto radica en la especificidad de los datos, que abarcan una amplia gama de temas relacionados con currículums y ofertas laborales. Esta diversidad de temas y el pequeño tamaño del conjunto de datos de entrenamiento (2048 entradas) dificultaron la capacidad del modelo para generalizar correctamente a datos no vistos. El modelo, al estar demasiado enfocado en los patrones específicos de los datos de entrenamiento, no pudo adaptarse adecuadamente a la variabilidad de las ofertas laborales en el conjunto de evaluación, lo que resultó en un overfitting persistente.

## **9. Casos de prueba exitosos**

Para nuestras dos pruebas principales seleccionamos una oferta de trabajo específica, en este caso la posición de *Bilingual Financial Analyst*. A partir de ella utilizamos diez currículums distintos como candidatos para evaluar el desempeño del sistema. Como resultado, el modelo generó para cada CV un porcentaje de compatibilidad respecto al puesto, indicando qué tan adecuado es cada aspirante. Además, el sistema mostró la información personal debidamente anonimizada como nombre, correo electrónico y número de teléfono junto con los datos que sí se mantienen visibles, como la localidad, la experiencia laboral y la formación académica.

**Figura 3**

*Interfaz de Usuario SPA: Selección de Ofertas Laborales en Empresa de Relojes*



*Nota.* Captura de la interfaz web de una SPA en Django que permite explorar ofertas laborales, cargar el currículum e iniciar el emparejamiento con el modelo de IA.

**Figura 4**

*Predicción del Modelo: Resultados de Dataset y Currículum Anonimizado*

**File 3**

**Prediction Score:** 0.8878248333930969

```
[NAME]
Email: [[EMAIL]](mailto:[EMAIL])
Phone: [PHONE]
Location: Milan, Italy
**Summary:***
[EDUCATION]
**Experience:***
**Senior Financial Controller - Luxury Watches Ltd (2014-2025)**

[EDUCATION]
* Supported internal audit cycles and compliance reviews.
* Coordinated financial reporting across business units.
**Financial Analyst - Elite Manufacturing Finance (2010-2014)**
* Assisted with budget preparation and variance analysis.
* Supported accounting audits and internal reporting processes.
**Skills:***
Budgeting, Forecasting, Internal Controls, Reporting, SAP Finance
[EDUCATION]
[EDUCATION]
[EDUCATION]
```

**File 4**

**Prediction Score:** 0.9887304902076721

```
[NAME]
[NAME]
Email: [[EMAIL]](mailto:[EMAIL])
Phone: [PHONE]
Location: Los Angeles, USA
**Summary:***
[EDUCATION]
**Experience:***
**Financial Analyst - Royal Horology (2018-2025)**

[EDUCATION]
* Collaborated with marketing and R&D teams to ensure financial alignment with brand initiatives.
* Developed financial models to optimize resource allocation and profitability.
```

*Nota.* Muestra del resultado generado por el modelo de emparejamiento de IA, donde se visualizan las predicciones de compatibilidad (prediction score) para dos de los diez datasets

utilizados. A la izquierda, el currículum original es anonimizado antes de ser procesado por el modelo, y a la derecha se presentan los puntajes de compatibilidad para las ofertas laborales más relevantes.

## 10. Casos de prueba en falla

Para la prueba de fallo utilizamos la misma oferta de trabajo y los mismos diez currículos empleados en las pruebas exitosas. En este caso nos enfocamos en el CV que obtuvo el porcentaje de compatibilidad más bajo. El sistema devolvió un valor negativo, lo cual indica que dicho perfil no es adecuado ni compatible con los requisitos del puesto seleccionado.

**Figura 5**

*Predicción del modelo: Resultados negativos de Dataset*

**Upload CV for Job Matching**

**ML Model Ready!** You can upload CVs now.

Select one or more job positions:

Bilingual Financial Analyst: Join our prestigious watch brand to manage and analyze financial c  
HR Generalist: As part of our elite team, you will manage recruitment, talent development, em  
Watchmaking Technician: Bring your expertise in haute horlogerie to repair, assemble, and ma  
Marketing Manager: Lead the development and execution of high-touch marketing strategies  
IT Support Specialist: Provide critical technical support for our boutique and global operations  
Accountant: Oversee the financial records and reporting for our luxury watch brand. You will e

Hold CTRL to select multiple job offers.

Upload CV files (PDF, DOCX, Images, JSON)

Choose Files | 10 files

Upload Documents

Results:

---

File 1

**Prediction Score:** -0.353637158870697

```
[NAME]
Email: [[EMAIL]](mailto:[EMAIL])
Phone: [PHONE]
Location: New York, USA
**Summary:**  

[EDUCATION]
**Experience:**  

[EDUCATION]
* Managed server environments and monitored network performance.  

* Collaborated with IT security teams to ensure system resilience.  

[EDUCATION]
```

*Nota:* La imagen muestra el funcionamiento del módulo donde se selecciona una oferta de trabajo, se cargan múltiples CV y se generan los puntajes de compatibilidad. En este caso, el sistema presenta un resultado negativo para uno de los candidatos, indicando que su perfil no se ajusta a los requisitos del puesto.

## **11. Conclusiones**

TalentMap AI es un programa académico que explora la aplicación de la ética y los principios técnicos de la IA en los procesos de selección de personal. Su misión es centrarse en el desarrollo de modelos de IA como núcleo conceptual, promoviendo la viabilidad técnica, el impacto social positivo y la alineación con los objetivos curriculares del curso. Este enfoque fomenta la comprensión del potencial transformador de la IA en los procesos humanos, priorizando la rendición de cuentas, la equidad y la explicabilidad como pilares fundamentales de su aplicación.

## Bibliografía

Chancellor, S., & De Choudhury, M. (2020). Methods in predictive techniques for mental health status on social media: a critical review. *Npj Digital Medicine*, 3(1).

<https://doi.org/10.1038/s41746-020-0233-7>

Dekker, G., Pechenizkiy, M., & Vleeshouwers, J. (2009). *Predicting students drop out: a case study*. <https://www.semanticscholar.org/paper/Predicting-Students-Drop-Out%3A-A-Case-Study-Dekker-Pechenizkiy/b0185d5ffa59106088125d82a3ca296bc5b09c87>

Eichstaedt, J. C., Smith, R. J., Merchant, R. M., Ungar, L. H., Crutchley, P., Preotiu-Pietro, D., Asch, D. A., & Schwartz, H. A. (2018b). Facebook language predicts depression in medical records. *Proceedings of the National Academy of Sciences*, 115(44), 11203–11208. <https://doi.org/10.1073/pnas.1802331115>

*Employee retention: What employee turnover really costs your company.* (2023, February 22). MGR Workforce. <https://mgrworkforce.com/employers/employee-retention-costs/>

Gilyadov, J. (2017, 23 marzo). *Word2Vec explained*. <https://israelg99.github.io/2017-03-23-Word2Vec-Explained>

*Help wanted.* (n.d.). Upturn. <https://www.upturn.org/work/help-wanted/>

Park, H. S., & Yoo, S. J. (2021). Early Dropout Prediction in Online Learning of University using Machine Learning. *JOIV International Journal on Informatics Visualization*, 5(4), 347. <https://doi.org/10.30630/joiv.5.4.732>

Raghavan, M., Barocas, S., Kleinberg, J., & Levy, K. (2020). Mitigating bias in algorithmic hiring. *Association for Computing Machinery*, 469–481.

<https://doi.org/10.1145/3351095.3372828>

Rosenberger, J., Wolfrum, L., Weinzierl, S., Kraus, M., & Zschech, P. (2025, March 3). *CareerBERT: Matching resumes to ESCO jobs in a shared embedding space for generic job recommendations*. arXiv.org. <https://arxiv.org/abs/2503.02056>

Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4th ed.). Pearson.  
[http://lib.yzu.am/disciplines\\_bk/efdd4d1d4c2087fe1cbe03d9ced67f34.pdf](http://lib.yzu.am/disciplines_bk/efdd4d1d4c2087fe1cbe03d9ced67f34.pdf)

Sáenz, M., & Sáenz, M. (2012, 5 febrero). *SELECCIÓN- Los costes de una mala contratación en la empresa pueden suponer hasta dos veces el salario anual del empleado*. ORH | Observatorio de Recursos Humanos. <https://www.observatoriorh.com/orh/seleccion-los-costes-de-una-mala-contratacion-en-la-empresa-pueden-suponer-hasta-dos-veces-el-salario-anual-del-empleado.html>

*The True Cost of Bad Hire* | Collavion. (s. f.). <https://collavion.com/insights/the-true-cost-of-bad-hire/>

UNESCO. (2021). *Recommendation on the Ethics of Artificial Intelligence*. Paris: UNESCO.  
<https://unesdoc.unesco.org/ark:/48223/pf0000380455>

Vojtko, R., & Vojtko, R. (2025, 4 junio). BERT Model – Bidirectional Encoder Representations from Transformers - QuantPedia. *QuantPedia - The Encyclopedia of Algorithmic and Quantitative Trading Strategies*. <https://quantpedia.com/bert-model-bidirectional-encoder-representations-from-transformers>

World Economic Forum. (2024). *The Future of Jobs Report 2024*. Geneva: WEF.

<https://www.weforum.org/publications/series/future-of-jobs/>

Zhao, X., Wang, M., Zhao, X., Li, J., Zhou, S., Yin, D., Li, Q., Tang, J., & Guo, R. (2023b,

October 28). *Embedding in Recommender Systems: A survey*. arXiv.org.

<https://arxiv.org/abs/2310.18608>